

Assignment 2 (written)

Chiu - 2021.1.27

$$J_{\text{naive-softmax}}(\mathbf{v}_c, \mathbf{o}, \mathbf{U}) = -\log \frac{\exp(\mathbf{u}_o^T \mathbf{v}_c)}{\sum_{w \in \text{Vocab}} \exp(\mathbf{u}_w^T \mathbf{v}_c)}$$
$$J_{\text{neg-sample}}(\mathbf{v}_c, \mathbf{o}, \mathbf{U}) = -\log(\sigma(\mathbf{u}_o^T \mathbf{v}_c)) - \sum_{k=1}^K \log(\sigma(-\mathbf{u}_k^T \mathbf{v}_c))$$
$$J_{\text{skip-gram}}(\mathbf{v}_c, \mathbf{w}_{t-m}, \dots, \mathbf{w}_{t+m}, \mathbf{U}) = \sum_{\substack{-m \leq j \leq m \\ j \neq 0}} J(\mathbf{v}_c, \mathbf{w}_{t+j}, \mathbf{U})$$

Note:

- 负采样不是单纯把 $w \in \text{Vocab}$ 改成了 k 从 1 到 K ，而是把分母整个改造成用 sigmoid 函数取 log 再求和
- naive-softmax 是在 log 里求 exp 的和，负采样是在 log 外求和，log 内为 sigmoid
- 【注意】负采样时负样本 $[1, K]$ 中不会出现正例 o !

Notation:

- u, v 均为 $d \times 1$ 的列向量
- 矩阵 U 维数为 $|\text{V}| \times d$ ，每行是 u^T
- y : 真实分布，是 one-hot (y_o 表示 outside word 的真实分布，即仅下标 o 处为 1)，这里约定是列向量
- \hat{y} : softmax 或负采样后的预测分布，这里约定是列向量 (\hat{y}_o 表示下标 o 处的 prob，即一个元素)

Naive-Softmax

(a) 由实际分布为 one-hot，即 $y_w = \begin{cases} 1, & w = o \\ 0, & \text{else} \end{cases}$ 可得交叉熵 loss = naive-softmax，即

$$CE(y, \hat{y}) = - \sum_{w \in \text{Vocab}} y_w \log(\hat{y}_w) = -\log(\hat{y}_o)$$

【注意】

- 含义：输入 softmax 参数 θ 得到预测分布 \hat{y} ，它的负 log 损失 \Leftrightarrow 对某个真实存在的分布 y 和这个预测分布 $\hat{y} = \text{softmax}(\theta)$ 计算交叉熵
- 这个等式可以推导出 naive-softmax 关于 θ 的微分：(word2vec 中 $\theta = \text{点积} = Uv_c$)

$$\frac{\partial J}{\partial \theta} = \frac{\partial CE(y, \hat{y})}{\partial \theta} = (\hat{y} - y)^T$$

◦ 令点积 $\theta = Uv_c$ ，概率列向量 $\hat{y} = \text{Prob} = \text{softmax}(\theta)$ ，则 $J = CE(y, \text{softmax}(\theta))$

- 交叉熵的微分 $\frac{\partial CE(y, \hat{y})}{\partial \theta} = \frac{\partial CE(y, \hat{y})}{\partial \hat{y}} \frac{\partial \hat{y}}{\partial \theta} = \sum_k \frac{\partial CE}{\partial \hat{y}_k} \frac{\partial \hat{y}_k}{\partial \theta}$ ，这里 softmax 函数的输入 $\theta = y$
 - 由 $\frac{\partial CE(y, \hat{y})}{\partial \hat{y}_w} = \begin{cases} 1/\hat{y}_o, & w = o \\ 0, & \text{else} \end{cases}$ ， $\frac{\partial \hat{y}_i}{\partial \theta_j} = \begin{cases} \frac{\exp(\theta_i)(\sum \dots) - \exp(2\theta_i)}{(\sum \exp(\theta_k))^2} = \hat{y}_i(1 - \hat{y}_i), & i = j \\ -\frac{\exp(\theta_i) \cdot \exp(\theta_j)}{(\sum \exp(\theta_k))^2} = -\hat{y}_i \hat{y}_j, & i \neq j \end{cases}$
 - 得 $\frac{\partial CE(y, \hat{y})}{\partial \theta_j} = \begin{cases} 1 - \hat{y}_o, & j = o \\ -\hat{y}_j, & j \neq o \end{cases}$ ，向量表示为 $y^T - \hat{y}^T$ ($1 \times d$)

- [上述推导左侧微分含有对word2vec中真实分布y的依赖，实际上可以给出一个无依赖的推导]

令Softmax := S, CE := L, 则

$$\begin{aligned}
 \frac{\partial L}{\partial \theta_j} &= - \sum_k y_k \frac{\partial \log S_k}{\partial \theta_j} \\
 &= - \sum_k y_k \frac{1}{S_k} \frac{\partial S_k}{\partial \theta_j} \\
 &= - \sum_{k=j} y_k \frac{1}{S_k} S_k (1 - S_k) - \sum_{k \neq j} y_k \frac{1}{S_k} (-S_k S_j) \\
 &= -y_j (1 - S_j) + \sum_{k \neq j} y_k S_j \\
 &= -y_j + S_j \sum_k y_k \quad (\text{由 Softmax 归一化知和为 1}) \\
 &= S_j - y_j
 \end{aligned}$$

(b)

$$\frac{\partial J_{\text{naive-softmax}}}{\partial v_c} = -u_o^T + \frac{\sum_{w \in \text{Vocab}} u_w^T \exp(u_w^T v_c)}{\sum_{w \in \text{Vocab}} \exp(u_w^T v_c)} = -u_o^T + \sum_{w \in \text{Vocab}} u_w^T P(O = w | C = c)$$

【发现】

- $\hat{y}_o = P(O=o | C=c) = y_o^T \cdot \text{softmax}(Uv_c)$, 即取出softmax中o对应行的元素
- 右部分是outside vectors (u是列向量, 转置成为行向量) 的加权平均, 权重就是估计它为context的概率
- 左部分可以看成估计它为context的概率是-1 (?)
- 最后得到的是一个行向量 (与shape convention相反)

(c)

$$\frac{\partial J_{\text{naive-softmax}}}{\partial u_w} = \begin{cases} -v_c^T + \frac{v_c^T \exp(u_o^T v_c)}{\sum_{w \in \text{Vocab}} \exp(u_w^T v_c)} = -v_c^T + v_c^T P(O = o | C = c), & w = o \\ \frac{v_c^T \exp(u_w^T v_c)}{\sum_{w \in \text{Vocab}} \exp(u_w^T v_c)} = v_c^T P(O = w | C = c), & w \neq o \end{cases}$$

【推导】

观察法: $\frac{\partial J_{\text{naive-softmax}}}{\partial v_c} = -u_o^T + \text{Prob}^T \cdot U = -y^T U + \text{softmax}(Uv_c)^T U = (-y + \hat{y})^T U$

$$\frac{\partial J_{\text{naive-softmax}}}{\partial U} = -y v_c^T + \text{Prob} \cdot v_c^T = (\hat{y} - y) v_c^T$$

链式法则: $\frac{\partial J_{\text{naive-softmax}}}{\partial v_c} = \frac{\partial J}{\partial \theta} \cdot \frac{\partial \theta}{\partial v_c} = (\hat{y} - y)^T U$

$$\frac{\partial J_{\text{naive-softmax}}}{\partial U} = \delta^T x^T = (\hat{y} - y) v_c^T$$

Neg-Sample

(d) $\sigma(x) = \frac{1}{1+e^{-x}}$, 得到 $\sigma'(x) = \sigma(x)(1 - \sigma(x))$

(e)

$$\begin{aligned}\frac{\partial J_{\text{neg-sample}}}{\partial v_c} &= -u_o^T [1 - \sigma(u_o^T v_c)] - \sum_{k=1}^K [1 - \sigma(-u_k^T v_c)] (-u_k^T) \\ \frac{\partial J_{\text{neg-sample}}}{\partial u_o} &= -v_c^T [1 - \sigma(u_o^T v_c)] \\ \frac{\partial J_{\text{neg-sample}}}{\partial u_k} &= -[1 - \sigma(-u_k^T v_c)] (-v_c^T)\end{aligned}$$

- 负采样中梯度的计算是O(K)的，比原来naive-softmax的O(|V|)明显减小，不需要遍历整个vocab;
- 可以利用sigmoid函数微分后是原输出的函数的特性，进行计算结果复用，计算量减小。

(f) 注意 J 是任意的loss term (naive-softmax / neg-sample), 且 $w \neq c$

$$\begin{aligned}\frac{\partial J_{\text{skip-gram}}}{\partial U} &= \sum_{\substack{-m \leq j \leq m \\ j \neq 0}} \frac{\partial J}{\partial U} \\ \frac{\partial J_{\text{skip-gram}}}{\partial v_c} &= \sum_{\substack{-m \leq j \leq m \\ j \neq 0}} \frac{\partial J}{\partial v_c} \\ \frac{\partial J_{\text{skip-gram}}}{\partial v_w} &= 0 \quad (w \neq c)\end{aligned}$$

【注意】

- J 是C维列向量，即有C个output
- U 是|V|×d维的矩阵
- $\partial J / \partial U$ 由于shape convention，形状和U相同